

基于多客户端 vfio-user 后端的 同主机虚拟机热迁移中 USB 存储设备透明直通

匿名投稿

稿件编号: usbvfioid-usb-migration

按双盲评审要求隐去作者姓名、单位与联系方式

摘要

将物理 USB 设备直通给虚拟机在存储、加密狗与仪器等场景中很有价值,但它与热迁移存在根本冲突:主机侧的设备会话(打开的文件描述符、已声明的接口、端点状态以及设备自身的内部状态)无法序列化,因此任何会拆除该会话的迁移路径都会迫使客户机(Guest)重新枚举设备。本文以 Cloud Hypervisor 与 usbvfioid(一个以 Rust 实现、模拟 xHCI 控制器的 vfio-user 服务端)为具体研究对象。

我们首先通过实测指出:迁移一台挂载了 vfio-user 设备的虚拟机时会发生**死锁**而非明确报错——目标端 VMM 在协议版本握手中阻塞了 199.9 秒,其间无任何日志、无错误输出。根因是 vfio-user 服务端仅调用一次 `accept()`,而该连接仍被源端持有,目标端的连接虽然在内核层面建立成功(监听队列 `Recv-Q=1`),却永远不会被服务。我们还通过源码分析说明:即使解决了连接问题,该设备的 `Pausable/Migratable` 均为空实现、其快照不含 BAR 与设备内部状态,因此设备状态本身也不会被迁移。

在此基础上,本文提出一套**无需修改 VMM**的设计。其关键观察是:vfio-user 的握手类命令(`Version`、`DeviceGetInfo`、`DeviceGetRegionInfo`、`GetIrqInfo`)根本不访问设备后端,只有数据面命令才访问。因此只要把后端锁从“按连接持有”改为“**按命令加锁**”,第二个客户端即可在第一个仍然连接的情况下完成握手,而设备状态始终留在共享后端中。围绕这一改动,我们还发现并修复了交接过程暴露出的两个进一步缺陷:(1)即将退出的源端会下发破坏性命令,覆盖存活端刚注册的中断线并解除其 DMA 映射;(2)在中断线完成切换之前的窗口内完成的传输,其完成中断被打到即将退出的 VMM 的事件描述符上而永久丢失,表现为复制静默卡死。我们分别以“中断归属者”规则与“注册新中断线后补发一次中断”加以修复。

测量方法学上,我们记录了若干必须修正的观测陷阱:目标端会以 `File::create()` 截断串口日志、迁移会重建串口设备从而重置 Guest 的 TTY、以及只读且跳过日志回放的挂载会隐藏最近的写入。因此本文的结论一律取自 **Guest 自身的日志**,而非宿主侧观测;并强调时序相关的缺陷必须通过重复实验而非单次通过来验证。

在真实 32 GB exfat U 盘直通给 Ubuntu 22.04 客户机的实验环境中,一次跨越迁移点的 128 MiB 文件复制在 **20/20** 次运行中成功完成:实测停机 **4–21 ms**(中位数 6 ms;目标 ≤ 2000 ms),数据校验和与源文件**逐字节一致**,Guest 侧**零重枚举、零复位、零 I/O 错误**。为把“修复起作用”与“这几次恰好没事”区分开,我们补齐了五类对照:**不迁移对照**(8/8 通过,

复制耗时与迁移臂同量级；无迁移可判，故仅做校验和判定）、**release 构建臂**（8/8 通过，复制快约 4.5 倍）、**关闭踢中断的负对照**（7/8 通过，1 次复制停在固定字节数且此后再无完成事件）、**朴素热拔插基线**（3/3 失败：Guest 内核记录 USB disconnect 与 I/O 错误，dd 返回非零、校验和不符），以及**故障注入套件**（用两个仅 debug 可见、运行时可开的环境钩子人为放大交接窗口）：**关闭归属守卫 0/5 通过**（Fisher 精确检验 $p < 0.0001$ ，Guest 出现 36s 的 DID_TIME_OUT 与重复 I/O 错误，这一项是确定性的）；500ms 窗口下开启踢中断 5/5 通过、关闭 4/10 通过（ $p = 0.044$ ，但在 6 个对比的 Holm 校正下不显著，仅作名义参考）；**把窗口放大到 5s 后，开启踢中断 8/8 通过、关闭 2/8 通过**（ $p = 0.007$ ，对 5% 与 80% 的效应量该样本的检验效力为 0.88）——踢中断的必要性由受控放大窗口确立，但即使 5s 窗口也并非必然失败，这与“丢失的中断只有当它恰为最后一个未完成命令时才致命”一致。

本文同时如实报告了尚未消除的限制：迁移会重置 Guest 串口控制台（属于 VMM 串口设备模型行为，与 USB 通路无关）；尚未实现显式的传输静默期（quiesce），因此丢失的中断是否致命取决于它是否恰为最后一个未完成命令（自然窗口是否非空取决于暂停时刻的确定方式：把 CH 自己的时钟与 usbvfioid 墙钟对齐后为 20 次中 4 次、4 个完成事件；用 harness 的迁移 epoch 锚定为 8 次、10 个；用迁移请求锚定则是 11 次、24 个的严格上界。三者在同一量级）；跨主机迁移需要协议级的设备状态区域，当前协议不携带所需状态。

关键词

虚拟化；热迁移；设备直通；vfio-user；USB；xHCI；Cloud Hypervisor；KVM

英文摘要见 main.pdf（paper/main.tex，IEEE 会议格式）。